

# Diagnóstico Precoce da Doença de Alzheimer: Uma Abordagem Baseada em Grafos e Sinais de EEG

Guilherme Alvarenga de Azevedo

Engenharia de Computação

CEFET-MG, Campus V

Divinópolis, Brasil

gui.alvarengas234@gmail.com

**Resumo**—A doença de Alzheimer é uma das principais causas de demência e uma condição devastadora, com impactos significativos na vida dos pacientes e de seus familiares. Apesar do aumento do número de casos, muitos pacientes ainda não recebem um diagnóstico adequado e precoce. Este artigo propõe uma abordagem simplificada para o diagnóstico de Alzheimer a partir da análise de sinais de eletroencefalograma (EEG), utilizando a teoria dos grafos e o algoritmo de Louvain para identificar padrões de ondas cerebrais associadas à doença. A partir de dados de EEG de pacientes diagnosticados com Alzheimer e controle, as potências de banda relativa (RBP) das ondas cerebrais Theta e Alpha foram utilizadas como características para distinguir os grupos. Os resultados mostraram que a separação entre pacientes com Alzheimer e controles foi eficiente, com 77,78% de precisão na identificação dos casos de Alzheimer. A metodologia proposta, baseada em grafos, demonstrou ser uma ferramenta útil para a pré-classificação de pacientes, embora as limitações do modelo, como a sensibilidade à idade e ao estado do indivíduo durante o exame, sejam aspectos a serem explorados em trabalhos futuros. Este estudo sugere que a análise de EEG, aliada à teoria de grafos, pode ser uma abordagem promissora para auxiliar no diagnóstico precoce de Alzheimer, funcionando como uma ferramenta complementar ao diagnóstico clínico.

**Palavras-chave**—Alzheimer, EEG, teoria dos grafos, diagnóstico precoce, Louvain, ondas cerebrais, RBP.

## I. INTRODUÇÃO

Segundo a ADI (*Alzheimer's Disease International*), novos casos de demência surgem a cada 3,2 segundos no planeta. E, de acordo com a organização, em 2020 havia mais de 55 milhões de diagnósticos, com a tendência de que esse valor dobre a cada 20 anos, atingindo cerca de 78 milhões em 2030 e ultrapassando os 139 milhões em 2050 [1].

Além disso, o cuidado para com pessoas acometidas por essa síndrome custou mais de 1 trilhão de dólares mundialmente em 2019. Desse valor, cerca de 50% são de custeio de cuidadores informais. Para além disso, essa condição ocupa a sétima posição entre as causas de morte e também é considerada uma das maiores causas de dependência de pessoas idosas em todo o mundo, conforme relatórios da OMS (Organização Mundial da Saúde) [2].

Nesse sentido, é importante destacar que a doença de Alzheimer representa entre 60% e 70% destes casos. E que, apesar de normalmente atingir pessoas idosas, há um crescimento alarmante de casos entre pessoas que ainda não completaram os 65 anos [1]. Isso é preocupante, já que, além dos dados supracitados, o Alzheimer é uma condição

cujos sintomas se iniciam com uma degeneração gradual dos neurônios na área entorrinal<sup>1</sup> do cérebro e têm como fim a atrofia total do encéfalo [3], gerando impactos devastadores - e muitas vezes fatais - para a vida dos indivíduos e de seus familiares.

Como agravamento da situação, estima-se que a maior parte dos portadores de algum tipo de demência não recebeu um diagnóstico formal ou, ainda, que recebeu um diagnóstico incorreto confundido entre essas condições. Mais especificamente, acredita-se que cerca de 75% da população mundial não foi devidamente diagnosticada e, portanto, sofre pela falta de cuidados especializados e de tratamentos demandados para esse tipo de doença [1]. Em vista disso, o Relatório Mundial do Alzheimer de 2011 [4], e outros trabalhos correlatos como Rasmussen et al. (2019) [5], mostram a importância de se haver intervenções antecipadas e diagnósticos precoces para mitigar a falta de tratamento da doença e o seu desenvolvimento para estágios mais avançados.

Com isso em mente, novas tecnologias e métodos passaram a ser desenvolvidos para preencher essa lacuna de insuficiência na área da saúde internacional. Nesse cenário, este artigo busca se basear em métricas já desenvolvidas com fundamento em descobertas da neurociência para então introduzir uma abordagem mais simplificada para o problema do diagnóstico de pessoas com Alzheimer. Para tal, utilizou-se a teoria dos grafos e o método de *Louvain*, publicado por Blondel et al. (2008) [7], aplicado a relacionamentos entre pacientes submetidos a exames de eletroencefalograma (EEG). Como objetivo, esperou-se encontrar padrões e, com isso, realizar uma separação e determinar um possível perfil de pacientes que buscam um diagnóstico prévio para essa doença.

Com o intuito de alcançar o propósito citado, este trabalho está organizado da seguinte maneira: a Seção II apresenta o referencial teórico, abordando os fundamentos neurocientíficos do EEG e os principais estudos relacionados ao diagnóstico e caracterização do Alzheimer. Em seguida, a Seção III detalha a metodologia empregada, com ênfase na aplicação da teoria dos grafos e do método de Louvain na análise dos sinais de EEG, além das métricas utilizadas para a criação dos relacionamentos de similaridade entre pacientes. A Seção IV

<sup>1</sup>área que se associa diretamente com o neocórtex e o hipocampo, sendo relacionada principalmente com a consolidação de memórias no cérebro [6]

expõe os resultados obtidos e promove uma discussão acerca da eficácia da abordagem proposta, enquanto a Seção V conclui o trabalho, destacando as contribuições, limitações e sugestões para pesquisas futuras.

## II. REFERENCIAL TEÓRICO

O EEG se trata da medição da voltagem induzida pelos sinais elétricos de conjuntos de neurônios em regiões do encéfalo, que é possibilitada pela fixação de eletrodos no escalpo. O posicionamento e a quantidade desses eletrodos dependem do padrão de exame utilizado, sendo, em sua maioria, o padrão 10-20 com 19 canais, como mostra a Figura 1.




Figura 1. EEG Padrão 10-20, com 19 canais fixados: Fp1, Fp2, F7, F3, Fz, F4, F8, C3, Cz, C4, P3, Pz, P4, T3, T4, T5, T6, O1, e O2. [9]

Apesar de ser um exame simples, não invasivo e indolor, suas aplicações abrangem desde a criação de interfaces cérebro-computador ou BCI (do inglês, *Brain Computer Interface*), como evidenciado por Machado et al. (2010) [10], até a identificação de distúrbios neurológicos. Nesse contexto, o diagnóstico prévio de pacientes em situações de risco para desenvolvimento de doenças degenerativas, como Alzheimer, torna-se possível e facilitado.

Para se possibilitar a análise de exames de EEG, já foi discutido por diversos autores, incluindo Bear et al. (2017) [8], que as principais ondas cerebrais são divididas entre:

- Ondas Delta, de 0,5-4 Hz, característica do sono profundo;
- Ondas Theta, de 4–8 Hz, característica de estados de sono e de vigília;
- Ondas Alpha, de 8–13 Hz, relacionada a estados calmos e de vigília;
- Ondas Beta, de 13–25 Hz, frequentes em estados de atenção em tarefas diárias ou resolução de problemas;
- Ondas Gamma, de 25–45 Hz, sinalizam um córtex ativado ou em alerta.

Estudos realizados nos últimos anos relacionam diversas métricas individuais e aplicam métodos baseados em análise de sinais de EEG, aprendizado de máquina e grafos para

diagnosticar ou classificar pacientes submetidos ao exame. Em Houmani et al. (2018) [11], foram utilizadas as métricas de entropia baseada em janelas de tempo, que mede a complexidade do sinal, e de modelagem *bump*, que mede a sincronia local do exame. Através disso, utilizaram um classificador baseado em SVM (Support Vector Machine) e conseguiram classificar os pacientes entre Alzheimer e SCI (Subjective Cognitive Impairment) sendo, este último, uma condição de desordem da memória que não é diagnosticado pelos exames padrões. Com essa análise e classificação, obtiveram uma acurácia de 91,6%. Isso prova que essas métricas são eficientes na distinção de pacientes com condições similares.

Do mesmo modo, o estudo trazido por Zheng et al. (2023) [12], lança mão da mesma base de dados utilizada no presente artigo. Nele, são utilizadas *features* de espectro, como RBP (Relative Band Power) e IQR (InterQuartile Range), *features* de complexidade, como a entropia aproximada ou de permutação, e *features* de sincronização, como o coeficiente de clusterização ou o comprimento do caminho característico. Através delas, foi demonstrada a eficiência da utilização de classificadores como SVM, *random forests* e árvores de decisão para esse tipo de tarefa. Obtendo por método, respectivamente, 88,54%, 95,86% e 95,65% de acurácia.

No mesmo sentido, os criadores da mesma base de dados Miltiadous et al. (2023) [13], exploraram as *features* de espectro, como RBP e SCC (*Spectral Coherence Connectivity*) para realizar a classificação. Esses autores, porém, optaram pela utilização de um modelo *DICE-net* para classificar os pacientes e alcançaram uma acurácia média de 83,28% na comparação entre pacientes com Alzheimer e de controle.

De maneira mais ampla, existem pesquisas que buscaram relacionar diretamente o aumento ou diminuição de ondas cerebrais em pacientes com Alzheimer. Nesse cenário, os estudos de Nishida et al. (2011) [14] analisaram o GFP (Global Field Power), que mede a força do campo elétrico de todo o cérebro, para comparar pacientes diagnosticados com Alzheimer e com a demência frontotemporal. Com isso, puderam concluir que os pacientes do primeiro grupo foram caracterizados por um aumento das ondas de baixa frequência (Theta e/ou Delta) e por uma diminuição de ondas de alta frequência (Alpha e/ou Beta).

Cabe ressaltar, também, estudos como os de Özbek et al. (2021) [15], que validam a realização de exames EEG em estado de repouso com pacientes idosos e a utilização da razão entre as ondas Alpha/Theta para distinguir pacientes com diagnóstico de Alzheimer precoce e pacientes de controle saudáveis. Esses últimos estudos servem como base para o presente artigo, em que se tem como objetivo a utilização dessas duas ondas como fatores de diferenciação entre pacientes com e sem Alzheimer, através da teoria de grafos.

## III. METODOLOGIA

Nesta seção estão discriminados todos os métodos utilizados para os processos de pré-processamento, modelagem, clusterização e visualização da solução proposta. Todas as partes citadas foram implementadas com a linguagem *Python*,

com tabelas no formato .CSV e imagens gráficas no formato .PNG. As imagens de grafos utilizadas foram exportadas através do *software Gephi*, já que essa ferramenta possibilita uma visualização interativa e uma configuração simplificada para os grafos. Todos os arquivos se encontram no repositório *Github* do autor G. A. de Azevedo (2025) [16], com instruções para a preparação do ambiente e execução dos algoritmos citados.

#### A. Base de Dados Utilizada

Como exposto anteriormente na Seção II, existem diversas maneiras de se abordar o problema do diagnóstico de pacientes com indicativos de Alzheimer através da análise dos sinais de EEG. Para tal, este trabalho lança mão de um conjunto de dados divulgado por Miltiadous et al. (2024) [17] na *OpenNeuro* - uma plataforma gratuita e dedicada ao compartilhamento de dados de exames neurais. Ele foi escolhido por possuir pacientes diagnosticados com Alzheimer (36), outros com demência frontotemporal (23) e os demais sem nenhuma dessas doenças (29), considerados como pacientes de controle. Além disso, foram informados o sexo e a idade dos pacientes, bem como seus resultados no teste de avaliação cognitiva MMSE. Os autores também disponibilizaram os arquivos de ondas cerebrais no formato .SET que, seguindo o padrão BIDS (*Brain Imaging Data Structure*), já foram pré-processados, aplicando um filtro de *Butterworth* às ondas (de 0,5-45 Hz), além de terem sido removidos os artefatos indesejados, como os de piscadas ou de movimento da mandíbula, através do *ICA* (*Independent Component Analysis*).

As características citadas facilitam a extração das *features* que foram escolhidas como fatores de comparação entre os pacientes, isto é, as potências de banda relativas (RBP) das cinco principais frequências de ondas da atividade cerebral.

#### B. Preparação dos Sinais de Onda

Para extrair as informações numéricas para cada formato de onda dos pacientes de interesse (os diagnosticados com Alzheimer e os de controle) baseou-se na descrição dada por Miltiadous et al. (2023) [18]. Isto é, cada exame foi separado nos 19 canais do EEG e cada um desses foi segmentado em janelas de tempo de 4 segundos com uma sobreposição de 50%.

Após isso, para transformar esses dados do domínio do tempo para o domínio da frequência e encontrar os valores de RBP para cada onda, o valor de PSD (*Power Spectral Density*) foi calculado utilizando o método de Welch, descrito, para este caso, por Solomon (1991) [19]. De maneira simplificada, este método consiste no cálculo do quadrado do módulo da transformada de Fourier de cada segmento sobreposto. E, por fim, esses valores são somados e essa soma é dividida pela quantidade de segmentos, obtendo, assim, o valor de PSD para determinada faixa de onda em determinado canal de um exame. Para se calcular o valor RBP, basta dividir o PSD da faixa em questão pelo valor PSD de todo o intervalo de frequência analisado, no caso, de 0,5 a 45 Hz. Dessa forma, para cada paciente, haveria 19 valores para cada uma

das 5 faixas de frequência do intervalo de interesse. Porém, também foi calculada a média desses 19 valores, e obteve-se 5 diferentes métricas para cada um (Delta, Theta, Alpha, Beta e Gamma).

Como já citado previamente, já foi verificado pela literatura que pacientes com Alzheimer possuem, em média, uma diminuição no RBP das ondas Alpha e um aumento no RBP das ondas Theta. Por conta disso, neste estudo, considerou-se como *feature*, também, a razão de Theta/Alpha, para que as diferenças entre esses valores pudessem ser utilizadas como fatores de comparação entre os pacientes posteriormente.

#### C. Modelagem em Grafo

Além do uso de aprendizado de máquina, uma semelhança entre os estudos que abordam a temática da classificação de pacientes com Alzheimer é o fato de normalmente modelarem os eletrodos utilizando grafos, realizando uma comparação entre as áreas do cérebro para encontrar fatores de coerência entre elas. Neste artigo, porém, a modelagem com grafos segue uma ideia distinta e procura relacionar os pacientes como nós e suas similaridades (ou pesos) como as arestas do modelo.

Para representar os nós, criou-se uma tabela para armazenar as características de cada paciente, sendo elas:

- Id - O número de identificação do paciente vindo da base de dados;
- Theta/Alpha - Razão entre o RBP das ondas Theta e Alpha;
- Delta - RBP das ondas Delta;
- Theta - RBP das ondas Theta;
- Alpha - RBP das ondas Alpha;
- Beta - RBP das ondas Beta;
- Gamma - RBP das ondas Gamma;
- MMSE - Resultado do teste de cognição, medido entre 1 e 30;
- Age - Idade que varia entre 49 e 79, com média de 67 anos;
- Group - Grupo ao qual o paciente pertence: Alzheimer (A) ou Controle (C).

Já para representar as arestas, todos os pacientes seriam interligados, porém, foi preciso encontrar os pesos de cada relacionamento. Para isso, inicialmente foi calculada a distância Euclidiana (ou de Pitágoras) entre cada par de nós da tabela, utilizando um vetor contendo apenas as *features* "Theta" e "Alpha" de cada nó. Esse método foi utilizado pelo fato de ser uma boa métrica de medição da menor distância entre dois pontos em um espaço com poucas dimensões. No caso, como utilizou-se um espaço de duas dimensões, é descrito pela Equação 1:

$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2} \quad (1)$$

O peso das arestas, por sua vez, foi calculado pela Equação 2:

$$w = \frac{1}{1 + d} \quad (2)$$

Uma problemática surge, porém, devido aos valores de RBP sempre estarem abaixo de 1, e muito próximos entre si. Assim, as distâncias  $d$  medidas entre cada par de nós se mantiveram abaixo de (0, 1). Por conta disso, elas foram multiplicadas por 100 para que a visualização fosse facilitada e o valor dos pesos se distribuisse melhor entre 0 e 1, para uma posterior aplicação de *threshold*. Sem isso, os pesos calculados pela Equação 2 seriam sempre acima de (0, 9) e dificultariam a eficiência dos métodos a serem utilizados para caracterizar as conexões entre os nós.

Como todos os nós foram conectados e, por conseguinte, possuem pesos entre si, foi necessário determinar um limite inferior para diminuir as conexões e facilitar a geração de comunidades do método utilizado. Outro ponto de destaque é o fato de os valores de RBP dos sinais de onda serem muito sensíveis e, com poucas mudanças, o valor do peso pode ser desproporcionalmente menor que o esperado de acordo com os diagnósticos dos pacientes. Por esse motivo, o *threshold* (ou limite) escolhido para repartir os dados foi de (0, 15), fazendo com que apenas as conexões muito pouco relacionadas fossem desconsideradas.

#### D. Modularização do Grafo

Após a modelagem do grafo estar completa, foi necessário encontrar métodos que auxiliam na busca de comunidades ou *clusters* interconectados por alguma característica. Com isso em mente, foi escolhido o método de *Louvain*, que se trata de um algoritmo guloso que busca maximizar a modularidade do grafo através de heurísticas desenvolvidas por Blondel et al. (2008) [7]. Por se tratar de um algoritmo heurístico, ele lança mão de operações randômicas para tentar melhorar seus resultados. Por isso, cada vez que o método roda, comunidades diferentes podem ser geradas. Para resolver este obstáculo, optou-se por desativar a randomização do algoritmo, permitindo, assim, a reprodutibilidade dos testes aqui propostos. Além disso, é importante destacar que o método de *Louvain* utiliza um parâmetro de resolução, que influencia diretamente no tamanho das comunidades. Este conceito representa a noção de tempo apresentada por Lambiotte et al. (2009) [20] e, por padrão, foi utilizado o valor 1.

Assim, a separação entre as comunidades teve como objetivo encontrar, também, alguma divisão entre os pacientes acometidos pelo Alzheimer e os que não foram diagnosticados com essa doença. Além de poder indicar informações sobre a relação entre a idade, as ondas cerebrais de interesse e possíveis características implícitas entre pacientes que fugiram do padrão esperado. Para contribuir com essas análises, também fora plotado um gráfico de dispersão das duas dimensões avaliadas ("Theta" e "Alpha") de todos os pacientes analisados, utilizando a biblioteca *seaborn* do *Python*.

#### E. Representação Visual

Para que as comunidades fossem visualizadas de maneira mais nítida e separadas de acordo com o peso das arestas, foi utilizado o método *ForceAtlas2*, divulgado por Jacomy et al. (2014) [21] como um dos principais algoritmos de *layout*

de grafos disponibilizado no *software Gephi*. Ele se baseia na ideia de espacializar as redes para transformá-las em mapas com influência de uma métrica de gravidade em relação às arestas.

Ao utilizar o *Python* foi necessário executar esse algoritmo em cada comunidade e, posteriormente, com todas em conjunto, utilizando um ponto centróide como base. Possibilitando, assim, a visualização gerada pelas bibliotecas *NetworkX* e *matplotlib* da maneira desejada.

Como última modificação da visualização, os nós foram preenchidos com a cor de sua respectiva comunidade, além de receberem um rótulo determinante de qual grupo pertencem (A ou C) e terem seus tamanhos aumentados de acordo com a razão "Theta/Alpha" previamente calculada, multiplicada por 80. Como já citado, esses aspectos foram implementados tanto via código em *Python*, como também na ferramenta *Gephi*.

### IV. RESULTADOS E DISCUSSÃO

Após toda a abordagem metodológica ser definida, os resultados alcançados por este estudo trazem contribuições importantes para a compreensão da relação entre as ondas cerebrais Theta e Alpha e o processo degenerativo natural do cérebro humano. E, também, traz à discussão uma nova maneira de tratar o problema do diagnóstico prévio de Alzheimer, ao simplificar a análise de sinais de EEG, considerando apenas dois sinais de onda e aplicando métodos da teoria de grafos entre os pacientes.

A primeira visualização gerada no *Gephi* se encontra na Figura 2, em que são visíveis os rótulos de cada nó e seus respectivos tamanhos de acordo com a razão "Theta/Alpha". O posicionamento foi realizado com o método *ForceAtlas2* e, como é possível observar, apesar de considerar apenas os pesos das arestas, ele já realiza uma boa distribuição entre os pacientes de acordo com a razão das duas ondas. É importante ressaltar que nesse passo ainda não há nem mesmo a aplicação do *threshold* citado na Seção III.




Figura 2. Grafo inicial gerado a partir da ferramenta *Gephi*

Uma segunda e significativa visualização dos dados se dá através da plotagem do gráfico de dispersão das duas dimensões utilizadas para se comparar os pacientes. O gráfico da Figura 3 mostra a composição do conjunto de dados e indica as cores relativas ao grupo pertencente.




Figura 3. Gráfico de dispersão de Alpha vs Theta dos pacientes

Como esperado, existe uma tendência dos pacientes com Alzheimer de se manterem em valores mais baixos no eixo vertical (Alpha RBP) e em valores maiores no eixo horizontal (Theta RBP). Com esse gráfico também percebem-se alguns casos que fogem à regra e que podem indicar duas principais causas. Primeiramente, como o exame foi realizado com os pacientes em estado de repouso, é normal que os valores RBP dessas ondas sejam mais consideráveis. Além disso, considerando as idades elevadas da maioria dos pacientes, com média de 67 anos, os processos degenerativos do cérebro são esperados e, portanto, alguns pacientes, mesmo que não diagnosticados com Alzheimer, podem possuir valores de RBP Theta e Alpha similares aos pertencentes a esses grupos.




Figura 4. Grafo reorganizado após a geração das comunidades no Gephi

Após a análise dos dados iniciais, foi executado o método de *Louvain* para obtenção de 3 comunidades distintas, que estão discriminadas na Figura 4, pelas cores verde (abaixo), lilás (à direita) e laranja (à esquerda). Através dessa execução, o valor da modularidade da rede foi determinado e é cerca de (0,114), um valor relativamente muito baixo. Isso indica que a rede está muito conectada, tanto entre as comunidades como, também, entre os nós dentro de uma comunidade. Isso é um fator que impacta na formação das comunidades, e aponta se a rede pode ser bem dividida entre diversos módulos ou não. Fora a modularidade, as principais características das comunidades estão descritas na Tabela I.

Tabela I  
CARACTERÍSTICAS DAS COMUNIDADES ENCONTRADAS

Carac./Comunidade	0	1	2
Cor	Verde	Lilás	Laranja
Nós	9	29	27
% Controle	0	34,5	70,4
% Alzheimer	100	65,5	29,6
Média (MMSE)	19,67	21,38	26,37
Média (Idade)	62,78	68,21	67,26

Tanto as características numéricas como as visuais induzem importantes noções da realização do exame de EEG em estado de repouso. Com elas, verifica-se que, em média, os pacientes do grupo A possuem um valor da razão Theta/Alpha maior que os demais. Isso é facilmente verificado pela comunidade 0, em que todos os nós são do grupo A e seus tamanhos estão entre os maiores de toda a rede.

Contudo, também percebe-se que há pacientes que, mesmo sem receber o diagnóstico de Alzheimer, possuem valores consideravelmente altos para essa razão e, por isso, foram incluídos na mesma comunidade (1) que boa parte dos portadores da doença. Observando melhor esses casos, foi possível perceber que em sua maioria os pacientes de controle dessa comunidade já ultrapassaram os 65 anos e, assim, os traços degenerativos naturais podem influenciar diretamente nas métricas desses indivíduos.

Já para a terceira comunidade (2), percebe-se que o tamanho dos nós são menores quando comparados com os das outras comunidades e, portanto, espera-se que nessa comunidade a maioria sejam pacientes de controle - o que foi comprovado na prática, como mostra a Tabela I. Todavia, também há alguns indivíduos com Alzheimer nessa comunidade, com alguns sendo até mais novos que os 65 anos. Para estes casos, pode-se supor dois motivos: a idade pode indicar que a doença ainda não atingiu um estágio degenerativo avançado; ou o estado do paciente não era de completo repouso no momento do exame e, portanto, as ondas características desses estados não foram devidamente captadas. Então, é importante destacar que muitos fatores podem ter influenciado nos resultados dos exames e estes se encontram fora do escopo de avaliação deste trabalho.

Assim, é possível afirmar que a utilização exclusiva das métricas de RBP das ondas cerebrais Theta e Alpha, permite realizar uma separação precisa, em que 28 dos 36 portadores de Alzheimer foram devidamente classificados, o que equivale

a 77,78% de todos os casos. Já para os pacientes de controle, obteve-se uma separação com a qual 19 dos 29 indivíduos foram classificados em conjunto, alcançando 65,52% dos casos analisados. Dessa forma, os resultados obtidos indicam que as estratégias aqui abordadas são suficientes para se produzir uma pré-classificação de pacientes submetidos a exames de eletroencefalograma que desejam encontrar um possível diagnóstico prévio para a doença de Alzheimer. Apesar disso, recomenda-se veementemente que seja buscado um diagnóstico médico especializado, já que a solução aqui proposta serve como um auxílio à identificação do Alzheimer e jamais substitui uma avaliação clínica profissional.

## V. CONCLUSÃO

Este estudo abordou o diagnóstico prévio da doença de Alzheimer a partir da análise de sinais de eletroencefalograma (EEG) de pacientes, utilizando a teoria dos grafos para identificar padrões de comportamento cerebral relacionados à doença. O principal objetivo foi simplificar a análise tradicional dos sinais de EEG, focando nas ondas cerebrais Theta e Alpha, por meio de uma modelagem em grafo e a aplicação do algoritmo de Louvain para a detecção de comunidades entre os pacientes.

Os resultados obtidos indicam que a abordagem proposta conseguiu, de maneira eficiente, separar os pacientes diagnosticados com Alzheimer dos controles, com uma taxa de acerto significativa. A utilização das métricas de potência de banda relativa (RBP) das ondas Theta e Alpha revelou-se eficaz para a distinção entre os grupos. Com a aplicação do método de Louvain, foi possível identificar três comunidades, sendo que a maioria dos pacientes com Alzheimer foi corretamente classificada, o que demonstra a viabilidade do método como uma ferramenta auxiliar para o diagnóstico precoce.

Apesar dos bons resultados, a análise também revelou alguns casos fora do padrão esperado, principalmente entre os pacientes de controle mais velhos, cujos sinais de EEG apresentaram características semelhantes aos de pacientes com Alzheimer. Esses resultados sugerem que outros fatores, como a idade avançada ou variações no estado de repouso durante o exame, podem afetar as métricas de EEG e influenciar a classificação. Além disso, a rede apresentou uma modularidade baixa, o que indica que as relações entre os pacientes são complexas e difíceis de dividir claramente em comunidades distintas.

Para melhorar o desempenho da abordagem proposta, algumas melhorias podem ser implementadas em estudos futuros. A inclusão de mais variáveis para análise, como informações relacionadas a outros exames de neuroimagem ou avaliações cognitivas, pode ajudar a refinar ainda mais a distinção entre os grupos. Além disso, técnicas de aprendizado de máquina mais avançadas, combinadas com a análise em grafos, poderiam ser exploradas para aumentar a precisão do modelo. A utilização de mais dados e a aplicação de técnicas de validação cruzada também poderiam melhorar a robustez dos resultados obtidos.

Em relação ao método de Louvain, seria interessante investigar diferentes valores de resolução para ver como eles

influenciam a detecção de comunidades, além de explorar alternativas heurísticas para a segmentação dos dados. Também vale ressaltar que o uso de técnicas de análise temporal dos sinais de EEG pode contribuir para um entendimento mais profundo do processo degenerativo do Alzheimer e de como ele se manifesta nas ondas cerebrais.

Dessa forma, este trabalho contribui para a área de diagnóstico de Alzheimer ao propor uma abordagem simplificada para a análise de EEG, utilizando grafos para agrupar pacientes com base em padrões de ondas cerebrais. Embora a solução aqui apresentada não substitua um diagnóstico médico especializado, ela oferece um valioso ponto de partida para a identificação precoce de indivíduos com sinais iniciais da doença, podendo, assim, ser uma ferramenta complementar na busca por tratamentos mais eficazes e na melhoria da qualidade de vida dos pacientes.

## REFERÊNCIAS

- [1] Alzheimer's Disease International. Dementia statistics. Disponível em: <https://www.alzint.org/about/dementia-facts-figures/dementia-statistics/>
- [2] World Health Organization. Dementia, 2023. Disponível em: <https://www.who.int/news-room/fact-sheets/detail/dementia>
- [3] A. Machado. Neuroanatomia Funcional. Atheneu, 4 Ed, 2022.
- [4] Alzheimer's Disease International. World Alzheimer Report 2011: The benefits of early diagnosis and intervention, 2011. Disponível em: <https://www.alzint.org/u/WorldAlzheimerReport2011.pdf>
- [5] J. Rasmussen, H. Langerman. Alzheimer's Disease - Why We Need Early Diagnosis. Degenerative neurological and neuromuscular disease, 9, 123–130, 2019. Disponível em: <https://doi.org/10.2147/DNND.S228939>
- [6] G. Lane, G. Zhou, T. Noto, C. Zelano, Assessment of direct knowledge of the human olfactory system, Experimental Neurology, 329, 113304, 2020. Disponível em: <https://doi.org/10.1016/j.expneurol.2020.113304>
- [7] V. D. Blondel, J.-L. Guillaume, R. Lambiotte, E. Lefebvre. Fast unfolding of communities in large networks, in Journal of Statistical Mechanics: Theory and Experiment, 2008 (10), P1000.
- [8] M. F. Bear, B. W. Connors, and M. A. Paradiso. Neurociências: Desvendando o Sistema Nervoso. Artmed Editora, 4 Ed, 2017.
- [9] M. A. Vázquez, A. Maghsoudi, I. P. Mariño. An Interpretable Machine Learning Method for the Detection of Schizophrenia Using EEG Signals. Frontiers in systems neuroscience, 15, 652662, 2021 <https://doi.org/10.3389/fnys.2021.652662>
- [10] S. Machado, F. Araújo, F. Paes, B. Velasques, M. Cunha, H. Budde, L. F. Basile, R. Anghinah, O. Arias-Carrión, M. Cagy, R. Piedade, T. A. de Graaf, A. T. Sack, e P. Ribeiro. EEG-based brain-computer interfaces: an overview of basic concepts and clinical applications in neurorehabilitation. Reviews in the neurosciences, 21(6), 451–468, 2010. Disponível em: <https://doi.org/10.1515/revneuro.2010.21.6.451>
- [11] N. Houmani, F. Vialatte, E. Gallego-Jutglà, G. Dreyfus, V. H. Nguyen-Michel, J. Mariani, K. Kinugawa. Diagnosis of Alzheimer's disease with Electroencephalography in a differential framework. PloS one, 13(3), e0193607. 2018. Disponível em: <https://doi.org/10.1371/journal.pone.0193607>
- [12] Zheng X., Wang B., Liu H., Wu W., Sun J., Fang W., Jiang R., Hu Y., Jin C., Wei X., and Chen S. S., "Diagnosis of Alzheimer's disease via resting-state EEG: integration of spectrum, complexity, and synchronization signal features,"Frontiers in Aging Neuroscience, vol. 15, p. 1288295, 2023, doi: 10.3389/fnagi.2023.1288295.
- [13] A. Miltiadous, E. Gionanidis, K. D. Tzamourta, N. Giannakeas and A. T. Tzallas, DICE-Net: A Novel Convolution-Transformer Architecture for Alzheimer Detection in EEG Signals. vol. 11, pp. 71840-71858, 2023, doi: 10.1109/ACCESS.2023.3294618.
- [14] K. Nishida, M. Yoshimura, T. Isotani, T. Yoshida, Y. Kitauro, A. Saito, H. Mii, M. Kato, Y. Takekita, A. Suwa, S. Morita, T. Kinoshita. Differences in quantitative EEG between frontotemporal dementia and Alzheimer's disease as revealed by LORETA. Clinical neurophysiology : official journal of the International Federation of Clinical Neurophysiology, 122(9), 1718–1725. 2011. Disponível em: <https://doi.org/10.1016/j.clinph.2011.02.011>

- [15] Y. Özbek, E. Fide, G. G. Yener. Resting-state EEG alpha/theta power ratio discriminates early-onset Alzheimer's disease from healthy controls. *Clinical neurophysiology : official journal of the International Federation of Clinical Neurophysiology*, 132(9), 2019–2031. 2021. <https://doi.org/10.1016/j.clinph.2021.05.012>
- [16] G. A. de Azevedo. Aplicação da Teoria de Grafos na Análise de sinais de Eletroencefalograma (EEG), 2025. Disponível em: <https://github.com/alvarengazv/eeg-analysis-with-graphs>
- [17] A. Miltiadous, K. D. Tzamourta, T. Afrantou, P. Ioannidis, N. Grigoriadis, D. G. Tsalikakis, P. Angelidis, M. G. Tsipouras, E. Glavas, N. Giannakeas, A. T. Tzallas, A dataset of EEG recordings from: Alzheimer's disease, Frontotemporal dementia and Healthy subjects. *OpenNeuro, Dataset*, 2024. [Online]. Disponível em: <https://doi.org/10.18112/openneuro.ds004504.v1.0.8>
- [18] A. Miltiadous, K. D. Tzamourta, T. Afrantou, P. Ioannidis, N. Grigoriadis, D. G. Tsalikakis, P. Angelidis, M. G. Tsipouras, E. Glavas, N. Giannakeas, A. T. Tzallas. A Dataset of Scalp EEG Recordings of Alzheimer's Disease, Frontotemporal Dementia and Healthy Subjects from Routine EEG. *Data*, 8(6), 95, 2023. Disponível em: <https://doi.org/10.3390/data8060095>
- [19] O. M. Jr Solomon. PSD computations using Welch's method. [Power Spectral Density (PSD)]. 1991. Disponível em: <https://doi.org/10.2172/5688766>
- [20] R. Lambiotte, J.-C. Delvenne, M. Barahona. *Laplacian Dynamics and Multiscale Modular Structure in Networks*, 2009.
- [21] M. Jacomy, T. Venturini, S. Heymann, M. Bastian. ForceAtlas2, a Continuous Graph Layout Algorithm for Handy Network Visualization Designed for the Gephi Software. 2014. *PLoS ONE* 9(6): e98679. Disponível em: <https://doi.org/10.1371/journal.pone.0098679>